

گزارش فاز دوم پروژه درس یادگیری ماشین

تهیه کننده: امیرحسین کارگران خوزانی

شماره دانشجویی: ۹۹۲۰۱۱۱۹

تیر ماه ۱۴۰۰

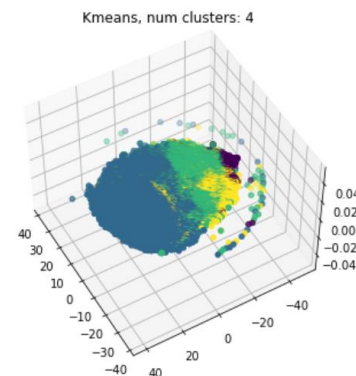

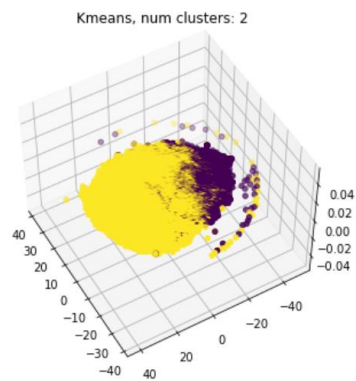

فاز دوم

- ▶ در پارت اول مدل‌های یادگیری ماشین بدون نظارت را بررسی می‌کنیم.
- ▶ در پارت دوم تاثیر دادگان بیشتر و عملیات **fine-tune** بر روی مدل **MLP** را بررسی می‌کنیم.

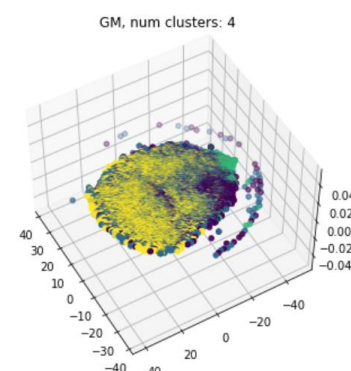



پارت اول: الگوریتم‌های دسته بندی

- ▶ الگوریتم `Kmeans`، `GMM` و `KmeansMiniBatch` (در کوئرا اجازه داده شد) برای بررسی انتخاب شدند و برای هر یک به ازای ۲، ۳ و ۴ کلاستر و برای هر یک از روش‌های `BOW` و `W2V` اجرا می‌شود.
- ▶ با استفاده از الگوریتم `TSNE` (طبق تجربه قبلی نسبت به `PCA` بهبود بهتری می‌دهد) به ۲ بعد کاهش انجام شده است و این دادگان درست است که در ادامه در `qube` نمایش داده شده اما در ۲ بعد هستند.
- ▶ برای حالت دو کلاسه چند متریک مختلف که به نقل از `sklearn` برای دسته بندی مناسب هستند انتخاب شد و مقایسه‌ای بین آن‌ها در ادامه انجام می‌شود ([منبع](#))



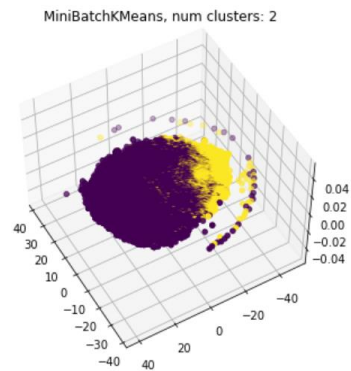
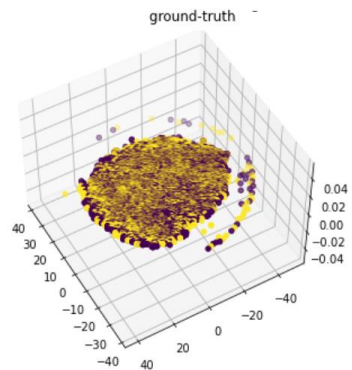
Kmeans: BOW



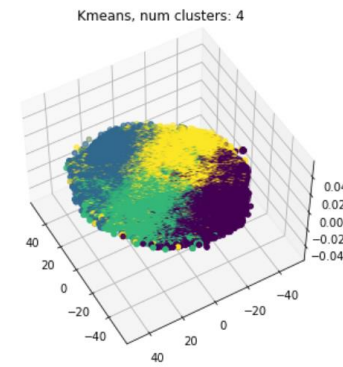
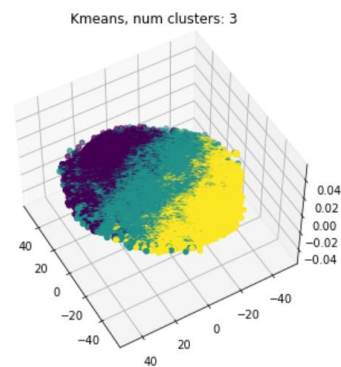
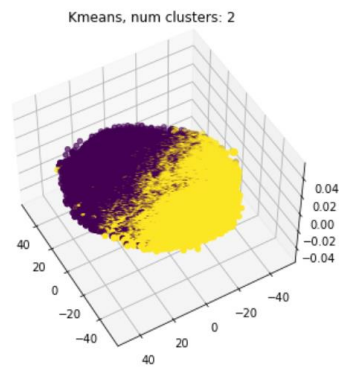

GMM: BOW



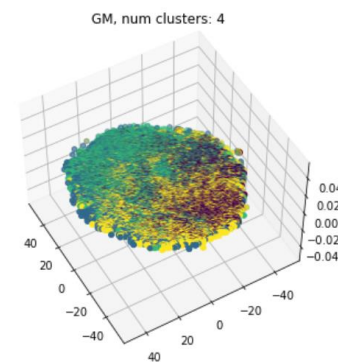


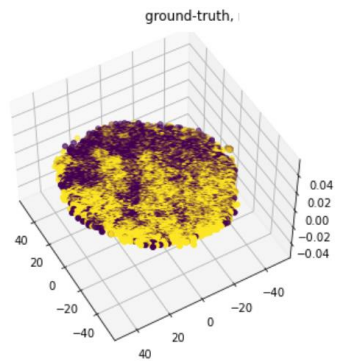
KmeansMiniBatch : BOW



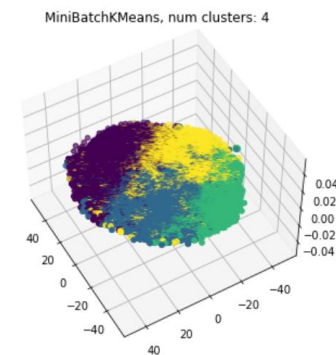

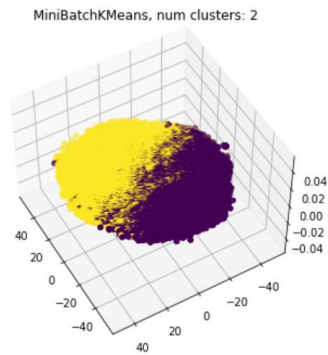

Kmeans: W2V



GMM: W2V



KmeansMiniBatch : W2V



آنالیز دسته بند دو کلاسه

► به این منظور تابع **analysis** را نوشتیم که معیارهای بیان شده در این [لینک](#) را محاسبه می کند. از آنجا که ممکن است کلاس ۰ و ۱ جا به جا شوند و برعکس میچ شده باشند ما یکبار بین برچسب های پیش بینی شده و اصل برچسب ها نتیجه ها را محاسبه کردیم و یک بار هم یکی از کلاس ها را برعکس کردیم و ماکسیمم را گزارش کردیم.

```
1 def analysis(labels, predictions):
2     predictions = np.array(predictions)
3     predictions2 = ~ np.array(predictions) + 2
4
5     print("Accuracy: \n", max(accuracy_score(labels, predictions), accuracy_score(labels, predictions2)))
6     print("Rand Score: \n", max(rand_score(labels, predictions), rand_score(labels, predictions2)))
7     print("Adjusted Rand Score: \n", max(adjusted_rand_score(labels, predictions), adjusted_rand_score(labels, predictions2)))
8     print("Adjusted Mutual Info: \n", max(adjusted_mutual_info_score(labels, predictions), adjusted_mutual_info_score(labels, predictions2)))
9     print("Homogeneity Score: \n", max(homogeneity_score(labels, predictions), homogeneity_score(labels, predictions2)))
10    print("Completeness Score: \n", max(completeness_score(labels, predictions), completeness_score(labels, predictions2)))
11    print("V Measure Score: \n", max(v_measure_score(labels, predictions), v_measure_score(labels, predictions2)))
12
```

ادامه آنالیز دسته بند دو کلاسه

► **Accuracy** که همان تعداد تشخیص‌های صحیح به کل تشخیص‌هاست.

► **Adjusted Rand index** و **Adjusted** شده آن نشان می‌دهد چقدر کلاس‌های ما به کلاس‌های اصلی شبیه هستند و این کار را با شماردن زوج‌ها انجام می‌دهد.

If C is a ground truth class assignment and K the clustering, let us define a and b as:

- a , the number of pairs of elements that are in the same set in C and in the same set in K
- b , the number of pairs of elements that are in different sets in C and in different sets in K

The unadjusted Rand index is then given by:

$$RI = \frac{a + b}{C_2^{n_{samples}}} \quad ARI = \frac{RI - E[RI]}{\max(RI) - E[RI]}$$

► **Adjusted Mutual info Score** نشان می‌دهد به چه اندازه فرکانس‌های مشاهده شده با کلاس‌های اصلی تفاوت دارد.

$$MI(U, V) = \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} \frac{|U_i \cap V_j|}{N} \log \left(\frac{N|U_i \cap V_j|}{|U_i||V_j|} \right) \quad NMI(U, V) = \frac{MI(U, V)}{\text{mean}(H(U), H(V))}$$

خروجی تابع analysis برای BOW

Kmeans

Accuracy:
0.5028444444444444
Rand Score:
0.5000050707299668
Adjusted Rand Score:
1.7462201752378123e-05
Adjusted Mutual Info:
2.1148680399360068e-05
Homogeneity Score:
3.450574636628788e-05
Completeness Score:
4.618141885943255e-05
V Measure Score Score:
3.9498830366416686e-05

GMM

Accuracy:
0.512
Rand Score:
0.500276895042112
Adjusted Rand Score:
0.0005561795579130826
Adjusted Mutual Info:
0.0004687535634002723
Homogeneity Score:
0.00046624153807074074
Completeness Score:
0.0005062793166172782
V Measure Score Score:
0.0004854362683024762

KmeansMiniBatch

Accuracy:
0.5008888888888889
Rand Score:
0.4999904689240008
Adjusted Rand Score:
-9.766296226834143e-06
Adjusted Mutual Info:
-1.4632920557867303e-05
Homogeneity Score:
3.793844150630643e-06
Completeness Score:
5.640713311406485e-06
V Measure Score Score:
4.536511073884152e-06

خروجی تابع analysis برای W2V

Kmeans

Accuracy:
0.6012444444444445
Rand Score:
0.5204902192888237
Adjusted Rand Score:
0.040980481130269905
Adjusted Mutual Info:
0.02985000012982743
Homogeneity Score:
0.029843807973999097
Completeness Score:
0.029887350643074843
V Measure Score Score:
0.02986556343772453

GMM

Accuracy:
0.5041333333333333
Rand Score:
0.5000230582901842
Adjusted Rand Score:
4.611851050913743e-05
Adjusted Mutual Info:
3.32781273056165e-05
Homogeneity Score:
4.930676388059054e-05
Completeness Score:
4.93106440969266e-05
V Measure Score Score:
4.930870391242276e-05

KmeansMiniBatch

Accuracy:
0.6035777777777778
Rand Score:
0.5214460775671558
Adjusted Rand Score:
0.042892160728089164
Adjusted Mutual Info:
0.031177454172053164
Homogeneity Score:
0.031189777300464135
Completeness Score:
0.031196196279916454
V Measure Score Score:
0.03119298645996144

نتیجه گیری

- ▶ در BOW الگوریتم GMM بهتر عملکردده است.
- ▶ در W2V الگوریتم Kmeans بهتر عملکردده است.
- ▶ الگوریتم ها به نقاط ابتدایی وابسته هستند و الگوریتم KmeansMiniBatch نسبت به پارامتر batch نیز حساس است.

نتیجه گیری بین دو کلاستر و سه کلاستر

- ▶ در هر ۳ الگوریتم با بررسی چند قیمت مختلف به صورت دستی مشاهده شد که کلاستر سوم دسته کوچکتري نسبت به دو کلاستر بزرگتر خواهد بود.
- ▶ ابتدا فکر کردم که معمولاً نظراتی در آن دسته با برچسب سوم قرار می‌گیرد که ممکن است هم منفی و یا مثبت باشد. اما مشاهده کردم که به نظر این بایاس من است که دلم می‌خواهد این نظرات چنین نظراتی باشند و مشاهده علمی‌ای نیست. اما می‌توان گفت که دسته سوم دسته کوچکتري است و دسته‌های اول و دوم با دسته‌های اول و دوم در کلاستر دوتایی اشتراک زیادی دارند.

پارت دوم: Fine-tuning

► ما ابتدا با استفاده از WordtoVec تنها بر روی همین دادگان محدود مدل MLP خود را با hyper parameter tuning آموزش می‌دهیم و بهترین دقت روی دادگان validation را گزارش می‌کنیم.

MLP: W2V

```
1 parameter_space = {
2     'hidden_layer_sizes': [(50,50,50), (50,100,50), (10,30,10), (20,), (50,), (100,), (150,)],
3     'activation': ['tanh', 'relu'],
4     'solver': ['sgd', 'adam'],
5     'alpha': [0.0001, 0.05, 0.1],
6     'learning_rate': ['constant', 'adaptive'],
7 }
8
9 best_param = {
10     'hidden_layer_sizes': parameter_space['hidden_layer_sizes'][-1],
11     'activation': parameter_space['activation'][-1],
12     'solver': parameter_space['solver'][-1],
13     'alpha': parameter_space['alpha'][-1],
14     'learning_rate': parameter_space['learning_rate'][-1],
15 }
16
17 best_score = 0
18
19 for hls in parameter_space['hidden_layer_sizes']:
20     for ac in parameter_space['activation']:
21         for so in parameter_space['solver']:
22             for al in parameter_space['alpha']:
23                 for lr in parameter_space['learning_rate']:
24                     clf = MLPClassifier(hidden_layer_sizes=hls, learning_rate=lr, alpha=al, solver=so, activation=ac, max_iter=1000)
25                     clf.fit(w2v_sentences_train2, Y_train2)
26                     score = accuracy_score(Y_val2, clf.predict(w2v_sentences_val2))
27
28                     if score > best_score:
29                         best_score = score
30                         best_param['hidden_layer_sizes'] = hls
31                         best_param['activation'] = ac
32                         best_param['solver'] = so
33                         best_param['alpha'] = al
34                         best_param['learning_rate'] = lr
35
36 print(best_score)
37 print(best_param)
```


ادامه Fine-tuning

► بهترین دقت روی دادگان validation برابر ۰٫۶ و بر روی دادگان تست برابر ۰٫۴ است.

```
0.6  
{'hidden_layer_sizes': (20,), 'activation': 'relu', 'solver': 'adam', 'alpha': 0.1, 'learning_rate': 'adaptive'}
```

```
1 analysis(Y_val2, clf.predict(w2v_sentences_val2))
```

Report Classification:

	precision	recall	f1-score	support
0	0.44	0.72	0.55	25
1	0.22	0.08	0.12	25
accuracy			0.40	50
macro avg	0.33	0.40	0.33	50
weighted avg	0.33	0.40	0.33	50

Matrix Confusion:

```
[[18  7]  
 [23  2]]
```

Accuracy:

```
0.4
```

ادامه Fine-tuning

- ▶ سپس بردارها را با استفاده از **Googlenews-Wordtovec** به فضای ۳۰۰ بعدی می‌بریم که مناسب داده شدن به ورودی بهترین مدل **MLP** فاز اول باشد.
- ▶ با استفاده از تابع **partial_fit** دادگان این مدل را نیز به بهترین مدل می‌دهیم و این فرآیند را چند بار انجام می‌دهیم.
- ▶ در نهایت دقت بر دادگان تست برابر ۰,۸۴ خواهد شد.

```
1 analysis(Y_val2, loaded_model.predict(w2v_sentences_val2))
```

Report Classification:

	precision	recall	f1-score	support
0	0.95	0.72	0.82	25
1	0.77	0.96	0.86	25
accuracy			0.84	50
macro avg	0.86	0.84	0.84	50
weighted avg	0.86	0.84	0.84	50

Matrix Confusion:

```
[[18  7]
 [ 1 24]]
```

Accuracy:

0.84

نتیجه گیری

► با استفاده از مدل‌های **pre-trained** شده که به دادگان بیشتری دسترسی داشته‌اند می‌توان دقت بهتری کسب نمود، به این منظور نیاز است که آن‌ها را **base** خود قرار داده و عملیات **fine-tune** انجام شود تا مدل مطابق آنچه که ما نیاز داریم بشود.

► شبیه این مساله را در مسائل تصویر نیز داریم، برای مثال شما یک شبکه رو برای تشخیص یک موجود استفاده کردی، سپس چندین لایه رو فریز می‌کنی و فقط چند لایه رو برای تشخیص یه موجود دیگر آموزش میدی، البته این کار وسیع تر است و **transferred learning** نامیده می‌شود. اما کانسپت این کار همان است چرا که کمک می‌کند با داده کمتر شبکه خوبی در نهایت داشته باشی.